Auto-Curriculum: ağ önce bulanık görmeyi seçer mi?

CMPE492 · Ömer Faruk Çelik, Mustafa Taha Söylemez · Danışman: Suayb S. Arslan · Rapor tarihi: 11 Kasım 2026 · Repo: github.com/omarreis01/autofocus-curriculum

30 epoch: 20 koşul × 3 seed bitti | 100 epoch: 7 koşul × 3 seed bitti | 81 checkpoint'te probe bitti | H1 reddedildi | H2: sıra değil, blur maruziyeti | Açık: yeni varyantlar 100 epoch'ta koşmadı

İçindekiler

1. Özet
2. Soru ve hipotezler
3. Literatür kısaca
4. Yöntem
5. Süreç ve sorunlar
6. Sonuçlar
7. Yorum: ne kadar eminiz?
8. Açık sorular ve sonraki adımlar
9. Ekler: tam tablolar, dosyalar, tekrar üretme

---

1. Özet

Soru. Bir teacher (bandit) her batch için blur ve contrast seviyesini seçer. Teacher, bebek görmesi gibi önce bulanık ve soluk görüntüyü seçer mi (H1)? Bu sıra ağa robustness ve shape bias kazandırır mı (H2)?

H1: Hayır. Denediğimiz hiçbir teacher bulanıktan başlamadı. Ham learning progress (PG, SPG) ile teacher uniform başlar, sonra en bozuk kola (σ=3, contrast 0.2) gider. Relative PG ve ALP-GMM uniforma yakın kalır.

H2: Sıra değil, blur maruziyeti. Blur görmek CIFAR-10-C, PGD ve shape bias'ı artırır. 100 epoch'ta CIFAR-10-C'de hiçbir sıra batch başına rastgele seçimi (random) geçemedi: random görülen 85.3, görülmeyen 84.4.

Ama yön önemli. Keskin→bulanık (reverse) en kötü sıra: görülmeyen 71.9, PGD 18.6 (100 epoch).

Contrast. Batch başına contrast eğitimi BatchNorm ile neredeyse etkisiz. Contrast sadece görüntü başına karışımda (88.9) veya GroupNorm ile (87.6) öğreniliyor.

Kapsam. CIFAR-10, ResNet-18, 3 seed. 30 epoch'ta 20 koşul, 100 epoch'ta 7 koşul.

---

2. Soru ve hipotezler

Motivasyon

Yeni doğan bebek bulanık ve düşük contrast'lı görür. Görme keskinliği aylar içinde artar. Bir görüş şudur: bu yavaş başlangıç bir hata değil, bir avantajdır. Önce kaba şekil öğrenilir, ince doku sonra gelir. Bu da görmeyi bozulmalara karşı daha sağlam yapabilir.

Literatürde bu fikir hep **elle** test edildi: araştırmacı bulanıktan keskine bir sıra yazar ve ağı onunla eğitir. Bizim sorumuz bir adım geri gider. Ağa ne göreceğini kendisi seçtirsek, o da bu sırayı seçer mi?

Hipotezler

- **H1:** Learning progress ile çalışan bir teacher, eğitimin başında bulanık ve soluk kolları, sonunda keskin kolları seçer.
- **H2:** Bu kendiliğinden çıkan sıra, kontrollere göre (aynı kolları rastgele sırayla görmek dahil) daha fazla robustness ve shape bias verir.

Tasarım kararı: robustness ödülde yok

Teacher'ın ödülü sadece eğitim verisindeki learning progress'tir (Graves 2017). Robustness, shape bias ve test verisi ödüle hiç girmez. Bunlar sadece eğitimin sonunda ölçülür. Sebep: robustness'ı ödüle koysaydık, teacher onu doğrudan optimize ederdi. O zaman "sıra kendiliğinden çıktı" diyemezdik.

3. Literatür kısaca

Çalışma	İddia	Bizim için önemi
Graves ve ark. 2017 (ICML)	Exp3.S bandit, learning progress ödülüyle hangi görevden örnek verileceğini seçer. Uniform örnekleme güçlü bir baseline.	Yöntemin iskeleti. PG ödülü yüksek varyanslı kollara kayabilir (Sec. 3.3). Bu yüzden SPG ve uniform kontrolü var.
Wang ve ark. 2023, 2024 (EfficientTrain, ++)	Önce düşük frekans, sonra tam görüntü. ImageNet eğitimi 1.5–3× hızlanır.	En yakın iş. Sırayı elle ve sabit verir. Robustness ölçmez. Sabit merdiveni bizim `staircase` kolumuz.
Wu, Dyer, Neyshabur 2021 (ICLR)	Standart eğitimde curriculum, anti-curriculum ve rastgele sıra eşit sonuç verir. Küçük kazanç pacing'den gelir.	Hakem sorusu: "Kazanç sıradan mı, maruziyetten mi?" Bu yüzden `shuffled`, `random`, `reverse` var.
Hacohen & Weinshall 2019 (ICML)	Curriculum = scoring + pacing. Kolaydan zora küçük kazanç (1–2 puan).	Bizde sıra ve süreyi aynı bandit seçer. Aynı LR schedule tüm koşullarda.
Portelas ve ark. 2019 (CoRL)	ALP-GMM: mutlak learning progress ile sürekli uzayda görev seçen teacher.	Farklı bir teacher kontrolü: `teacher_alp`.
Arslan, Jang, Sinha 2024 (CCN)	İç nöral gürültüyü yüksekten düşüğe indirmek robustness verir. Önce düşük çözünürlük de yardım eder. Sıralar elle verilmiş.	Danışmanın işi. Biz "aynı sıra kendiliğinden çıkar mı?" diye soruyoruz. Contrast bizim ekimiz.
Jang & Tong 2021	Nesne tanımada bulanık→net eğitimin robustness kazancı eğitim sonunda kalmıyor.	H2 için ön uyarı: sıra etkisi silinebilir.
Jang & Tong 2024	Karışık (bulanık + net) eğitim güçlü bir baseline.	`random` ve `random_blur` kontrollerinin nedeni.
Katzhendler & Weinshall 2019	Bulanık başlangıç argümanına itiraz: etki maruziyetten gelebilir.	Maruziyeti sıradan ayırmak gerekir: `shuffled`.

Kaynak: `docs/okuma/okuma_notlari_curriculum.md`, `docs/okuma/*.md`. Jang & Tong ve Katzhendler & Weinshall satırları okuma rehberindeki kısa özetten (`docs/progress.md`, 13 Ekim); bunlar için ayrıntılı not yok.

4. Yöntem

4.1 Veri, model, eğitim

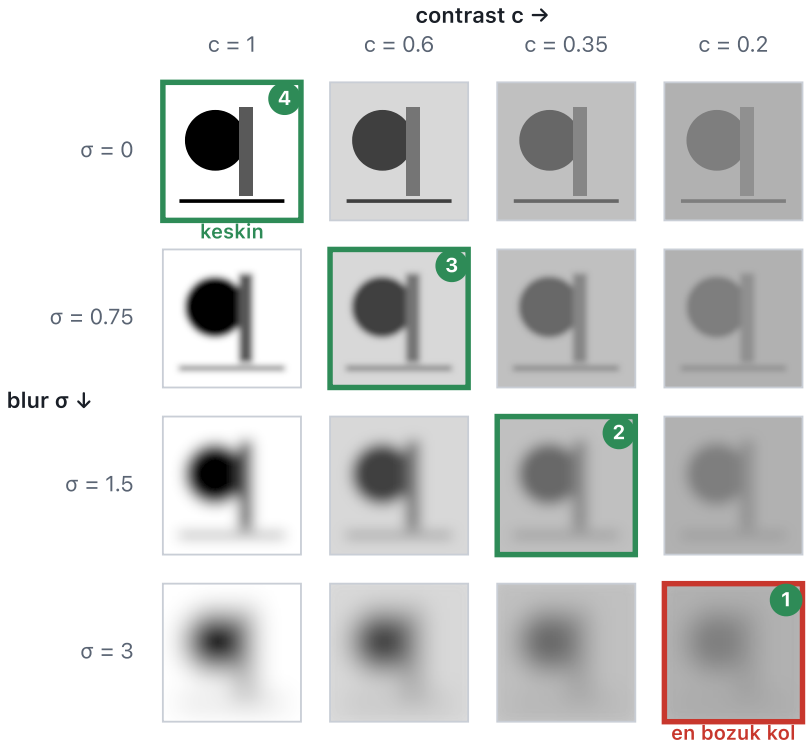
Veri	CIFAR-10 (50k train, 10k test). Augmentation: random crop (padding 4) + horizontal flip. Blur ve contrast GPU'da, augmentation'dan sonra uygulanır.
Model	ResNet-18, CIFAR varyantı (3×3 stem, max-pool yok). Varsayılan BatchNorm; bir deney grubunda GroupNorm(32).
Optimizer	SGD, Nesterov momentum 0.9, weight decay 5e-4, batch 512, bf16 AMP.
LR	Tepe 0.2. İlk %15 lineer warmup, sonra cosine ile sıfıra. Tüm koşullarda aynı.
Bütçe	Kısa = 30 epoch (2 910 adım). Tam = 100 epoch (9 700 adım). 97 adım/epoch.
Seed	0, 1, 2. Tüm sayılar 3 seed'in ortalaması ± std.

Kaynak: `src/train.py` (DEFAULTS, satır 18–39; SGD satır 143), `src/model.py`, `src/data.py` (augment).

4.2 Kollar: 4 blur × 4 contrast = 16 kol

Her kol bir (σ, c) çiftidir. σ Gaussian blur'un standart sapması (piksel). c contrast çarpanıdır: her görüntü kendi ortalamasına doğru sıkıştırılır, `x' = m + c·(x − m)`. Bir batch'in tüm görüntüleri aynı kolu alır (tek istisna: `random_image`).

16 kol: sol üst keskin, sağ alt en bozuk; staircase köşegeni izler



Şematik çizim (gerçek CIFAR görüntüsü değil). Blur, 32 px görüntü ölçeğine göre çizildi. Yeşil numaralar staircase sırası (1→4, sonra keskin). Kaynak: `src/degrade.py`, `src/schedule.py` (staircase).

4.3 Teacher: Exp3.S ve ödüller

1. Her adımda teacher 16 kol üzerinde bir olasılık dağılımından bir kol seçer.
2. Batch o kolla bozulur. Ağ bir SGD adımı atar.
3. Ödül ölçülür:
   - **PG** (prediction gain): aynı batch'te update öncesi loss – update sonrası loss. Bir ek forward pass.
   - **SPG**: aynı koldan *yeni* bir batch'te update öncesi ve sonrası loss farkı. Aynı batch'i ezberleme yanlılığını önler.
   - **RPG** (relative PG): PG ÷ update öncesi loss. Loss seviyesinin ölçeğini kaldırır.
4. Ham ödül [–1, 1] aralığına ölçeklenir: son 1000 ham ödülün 20. ve 80. persentiline göre (Graves 2017, Eq. 2).
5. Exp3.S güncellemesi: `w[kol] += η · r / p[kol]` (importance weighting). Sonra α=1/t ile ağırlıklar paylaşılır (non-stationary). Örnekleme: `(1−ε)·softmax(w) + ε/16`.

Parametreler: η = 0.01, ε = 0.05, α = 1/t, ödül penceresi 1000. η Graves'in 1e-3 değerinin 10 katı. Sebep: Graves ~10^5 adım koşar, biz 3k–10k. 1e-3 ile politika hiç kıpırdamıyordu. Ölçüm forward'ları BatchNorm running stats'ı değiştirmez.

Kaynak: `src/teacher.py` (RewardScaler, Exp3S, Teacher), `src/teacher_alp.py` (ALP-GMM), `docs/plans/colab-deneyler.md` "F2/F3 kararları".

4.4 Koşullar ve neyi test ettikleri

Koşul	Ne yapar	Neyi test eder
ANA 7 KOŞUL (30 VE 100 EPOCH)		
`sharp`	Hep keskin (σ 0, c 1).	Alt sınır: blur görmeyen model.
`random`	Her batch'e uniform rastgele kol.	Sırasız maruziyet.
`staircase`	Köşegen 4 adım (σ3,c.2)→(1.5,.35)→(.75,.6)→(0,1), eğitimin ilk %50'sinde; sonra keskin.	Elle bulanık→keskin. H1'in beklediği sıra.
`reverse`	Staircase'in zamanda tersi. Aynı kol sayıları.	Sıranın yönü önemli mi?
`teacher_pg`	Exp3.S + PG.	Ana yöntem.
`teacher_spg`	Exp3.S + SPG.	PG'nin aynı-batch yanlılığı.
`shuffled`	Aynı seed'in `teacher_pg` kol log'u, zamanda karıştırılmış.	Aynı maruziyet, sıra yok. Sıranın saf etkisi.
A — TEACHER VARYANTLARI (SADECE 30 EPOCH)		
`teacher_rpg`	PG ÷ loss.	Hard-first PG ölçeğinden mi geliyor?
`teacher_pg_eta0.003` , `_eta0.03`	η ×0.3 ve ×3.	η hassasiyeti.
`teacher_pg_noiw`	Importance weighting yok.	Güncelleme ayrıntısı.
`teacher_alp`	ALP-GMM (Portelas 2019), sürekli (σ, c) uzayı, en yakın kola yuvarlanır.	Farklı teacher aynı şeyi seçer mi?
B — EĞİTİM REJİMİ (SADECE 30 EPOCH)		
`random_image`	Her görüntüye ayrı rastgele kol (karışık batch).	Batch başına mı, görüntü başına mı?
`sharp_gn` , `random_gn` , `teacher_pg_gn`	BatchNorm yerine GroupNorm(32).	Sonuçlar BN'ye bağlı mı?
`random_blur`	Sadece blur ekseni (c = 1, 4 σ).	Robustness hangi eksenden?
`random_contrast`	Sadece contrast ekseni (σ = 0, 4 c).	Aynı soru.
`staircase_f025` , `_f075`	Merdiven eğitimin %25'i veya %75'i.	Elle merdivenin uzunluğu.

Kaynak: `src/make_configs.py` , `src/schedule.py` , `docs/plans/genis-deneyler.md` .

4.5 Ölçümler

- **Clean:** CIFAR-10 test doğruluğu.
- **CIFAR-10-C:** 19 bozulma × 5 şiddet. İkiye ayrılır. **Görülen** (eğitimdeki bozulmaya benzeyen 6 tane): gaussian, defocus, glass, motion, zoom blur ve contrast. **Görülmeyen:** kalan 13 (gürültüler, hava, sıkıştırma vb.). "Gürültü" sütunu 4 gürültü bozulmasının ortalaması. "C-contrast" sadece contrast bozulması.
- **Shape bias (CIFAR proxy):** hibrit görüntü = A sınıfının düşük frekansı (Gaussian σ=2) + B sınıfının yüksek frekansı. Shape bias = A'yı seçme payı ÷ (A + B payı). ~10k çift, farklı sınıflar. Bu Geirhos stil transferi değil; düşük ve yüksek frekansa dayanmayı ölçer.
- **Low-pass / high-pass doğruluk:** σ 1–3. Raporda high-pass σ=1.
- **PGD-10:** L∞, ε = 1/255 (raporlanan), adım ε/4, rastgele başlangıç, 2000 test görüntüsü. FGSM de ölçüldü ama gradient masking şüphesi var; kullanmıyoruz (Bölüm 7).

4.6 BatchNorm recalibration

Her eval ve probe'dan önce BN running stats sıfırlanır. Sonra 100 batch temiz *train* görüntüsüyle yeniden hesaplanır. Test verisi kullanılmaz. Neden gerektiği Bölüm 5'te. Geri almak: `python -m src.eval --no-recal` .

Kaynak: `src/eval.py` `recalibrate_bn` (satır 13–29), `src/probe.py` .

4.7 Altyapı

- Kod repo'da yaşar (`src/`). Colab sadece başlatıcı: `git clone` , sonra arka planda script (`nohup`). Sonuçlar ve checkpoint'ler Google Drive'a yazılır.
- Colab Pro, A100. 2.0 s/epoch (eager). `torch.compile` 1.7 s/epoch ama 30 s derleme ister; kullanılmadı. Tam CIFAR-10-C eval 15 s.
- Tüm veri GPU belleğinde durur. Aynı A100'de 6 koşu paralel koşar.
- Checkpoint her 5 epoch'ta. `--resume` kaldığı yerden devam eder. Kol sırası ve veri sırası resume'dan sonra aynıdır.
- Veri Hugging Face mirror'larından iner (~1.5 dk). CIFAR-10: `liangnanying/cifar-10-python` (md5 kontrollü). CIFAR-10-C: `robro/cifar10-c-parquet` (etiket sırası CIFAR-10 test ile birebir doğrulandı).
- Testler: pytest, 52 test (degrade, teacher, koşullar, probe, resume). CPU'da `--fake-data` ile smoke test.

---

5. Süreç ve sorunlar

`Ekim başı – 11 Ekim`
Okuma: Graves 2017, EfficientTrain/++, Wu 2021, Hacohen 2019, Portelas 2019, danışmanın CCN 2024 bildirisi. Notlar `docs/okuma/` .

`13 Ekim`
Proposal: H1/H2, 7 koşul, CIFAR-10 + ResNet-18 (`docs/project_proposal.pdf`).

`3 Kasım`
Kurulum ve pilot. Repo, Colab başlatıcı, degrade/train/eval, Exp3.S teacher ve kontroller (24 test). İlk GPU koşusu: sharp 30 epoch clean 93.2 (hedef ~93). Pilot: 7 koşul, seed 0.

`3 Kasım – sorun: yavaş indirme`
Zenodo (CIFAR-10-C) ve Toronto (CIFAR-10) sunucuları çok yavaştı. Çözüm: Hugging Face mirror'ları; tüm veri ~1.5 dk. Mirror'ın etiket sırası resmi test setiyle karşılaştırıldı.

`3–4 Kasım – sorun: BatchNorm uyumsuzluğu`
Aşağıda ayrıntılı.

`4 Kasım`
BN düzeltmesi (eval öncesi recalibration). F5: 7 koşul × 3 seed × 30 epoch. F6 (100 epoch) başladı. Genişletilmiş deney planı yazıldı (`docs/plans/genis-deneyler.md`).

`8 Kasım`
F6 bitti. Genişletilmiş kod (52 test). 13 yeni koşul × 3 seed + tüm 81 checkpoint'te probe (shape bias, low/high-pass, FGSM, PGD).

`8 Kasım – sorun: CUDA OOM`
12 koşu paralel çalışırken 3 koşu (GroupNorm ve per-image koşuları) GPU belleği yetmediği için öldü. Çözüm: 6 paralel ile checkpoint'ten yeniden koşuldu (`colab/finish_ext.sh`). Kurulum aynı, sonuç etkilenmez.

BatchNorm uyumsuzluğu

Ne oldu? Pilot'ta `sharp` normaldi. Ama karışık kol gören koşullar (random, teacher, shuffled, reverse) temiz testte %13–60 aldı. Bu, aynı ağın robustness sonuçlarıyla uyuşmuyordu.

Neden? Her batch tek bir kolla bozulur. BN eğitimde batch istatistiğini kullanır, sorun yok. Ama running stats (eval'de kullanılan) bozuk batch'lerin karışık ortalamasıdır. Temiz test görüntüsüne uymaz.

Nasıl bulduk? Hipotezi test ettik: BN running stats'ı 100 batch temiz train görüntüsüyle yeniden hesapladık. Random 60 → 89.1, teacher_spg 16 → 87.2 clean. Sharp değişmedi. Hipotez doğrulandı (`results/short/pilot_bn_recal.json`).

Düzeltme. Her eval ve probe'dan önce recalibration (Bölüm 4.6). Tüm raporlanan sayılar bununla.

> **Yan etki: contrast.** Aynı mekanizma eğitimde de çalışır. Bir batch'in tamamı aynı c ile sıkıştırılınca, ilk katmandan sonraki BN bu ölçek değişimini büyük ölçüde normalize eder. Ağ düşük contrast'ı neredeyse hiç "görmez". Bu yüzden batch başına contrast eğitimi contrast bozulmasına yardım etmiyor. Bu bir açıklamadır; onu destekleyen deneyler Bölüm 6.5'te (görüntü başına karışım ve GroupNorm).

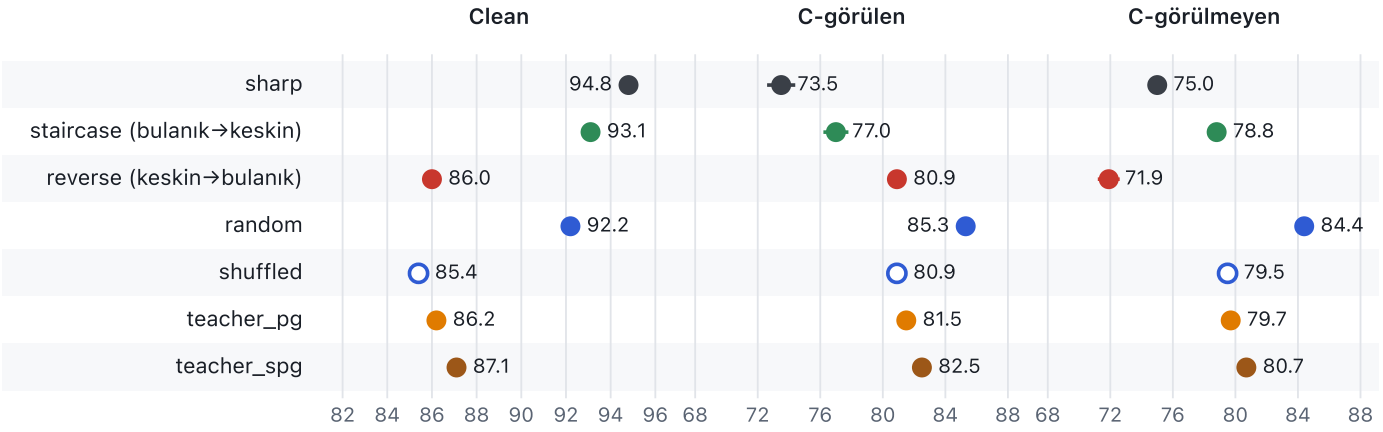
6. Sonuçlar

Tüm sayılar % doğruluk, 3 seed ortalaması ± std. C = CIFAR-10-C. Renkler tüm grafiklerde aynı:

sharp — staircase (bulanık→keskin) — reverse (keskin→bulanık) — random — shuffled — teacher_pg — teacher_spg — teacher_rpg — teacher_alp

6.1 Ana karşılaştırma (100 epoch)

100 epoch: random CIFAR-10-C'de en iyi; sharp clean'de en iyi ama C'de en kötüler arasında



Nokta = 3 seed ortalaması, çizgi = ± std (çoğu noktadan küçük). Eksenler sıfırdan başlamaz. Kaynak: `results/full_summary.json` (D["full:*"]), `docs/experiments.md` #6.

- Random C-görülen 85.3 ve C-görülmeyen 84.4 ile en iyi. Clean 92.2, sharp'tan sadece 2.6 puan düşük.
- Teacher'lar (pg, spg) ve shuffled clean'de 85–87'de kalır. Sebep: zamanlarının çoğunu en bozuk kolda geçirirler (6.3).
- Staircase sharp'a yakın: clean 93.1, C 77.0 / 78.8. Bulanık faz bitince model keskine uyum sağlıyor.
- Reverse C-görülen'de iyi (80.9) ama C-görülmeyen'de en kötü (71.9).

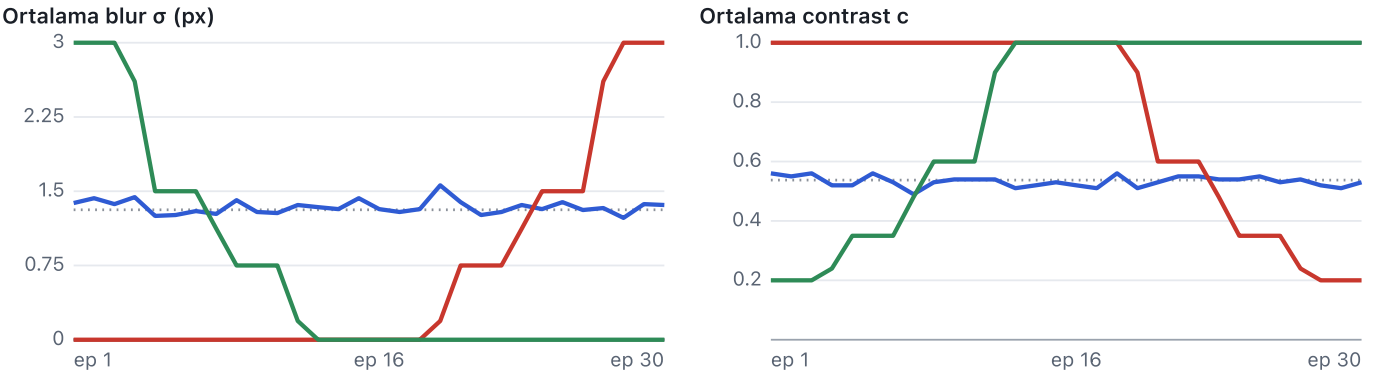
30 epoch'ta sıralama aynı (Ek tablo A).

6.2 Eğitim boyunca blur ve contrast

Bu bölüm H1'in doğrudan cevabı. Her çizgi: o epoch'ta eğitilen batch'lerin ortalama blur σ'sı ve ortalama contrast'ı (3 seed ortalaması). H1 doğru olsaydı teacher çizgisi staircase gibi yüksek σ / düşük c'den başlayıp aşağı (σ) ve yukarı (c) inerdi. Gri noktalı çizgi uniform seçimin beklenen değeri (σ 1.31, c 0.54).

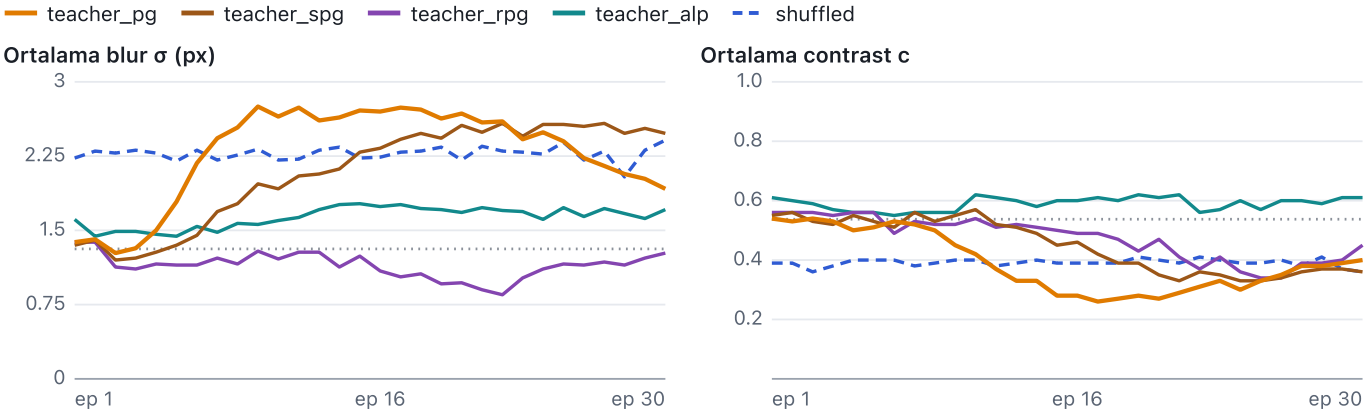
30 epoch, sıralar: staircase bulanıktan başlar, reverse bulanıkta biter, random sabit

sharp — staircase (bulanık→keskin) — reverse (keskin→bulanık) — random



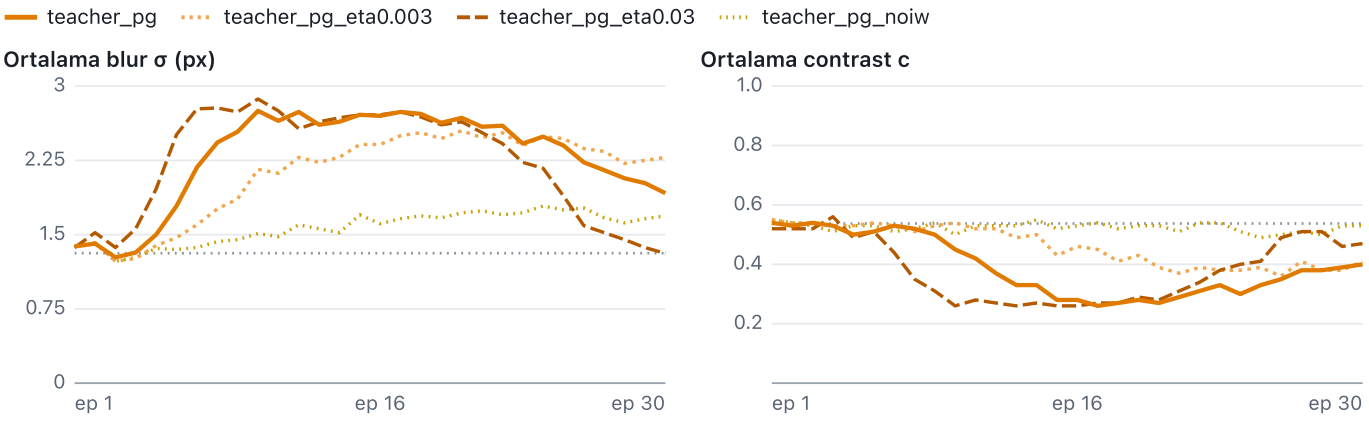
Sol: ortalama blur σ (px), yukarı = daha bulanık. Sağ: ortalama contrast, aşağı = daha soluk. Kaynak: CV.short, `src/blur_curve.py` (arms.npy).

30 epoch, teacher'lar: hiçbiri bulanıktan başlamıyor; PG ve SPG zamanla daha bulanık ve soluk kollara gidiyor



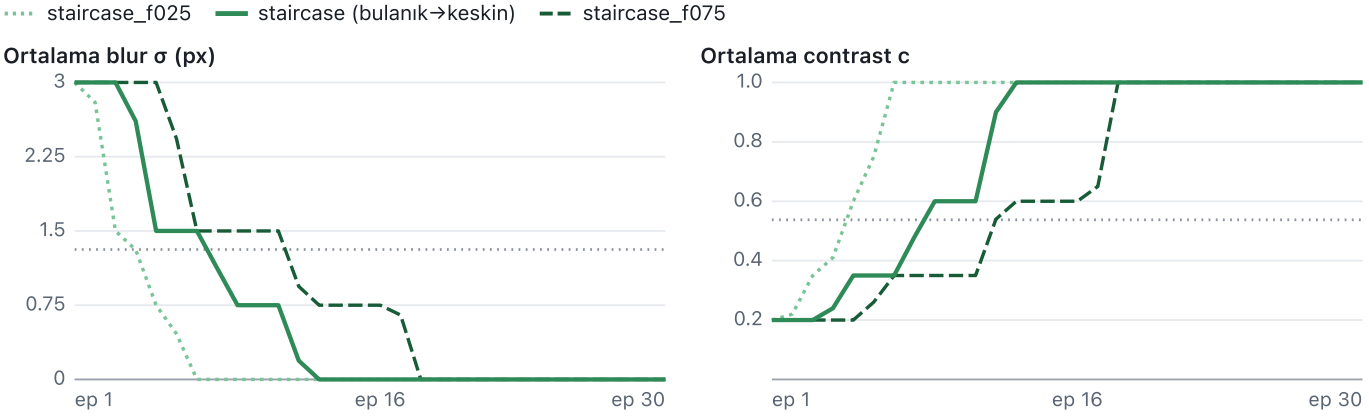
Shuffled, teacher_pg ile aynı kolları karışık sırayla görür; bu yüzden düz bir çizgi. Kaynak: CV.short.

30 epoch, PG varyantları: η sadece hızı değiştiriyor; importance weighting olmadan kayma yavaş



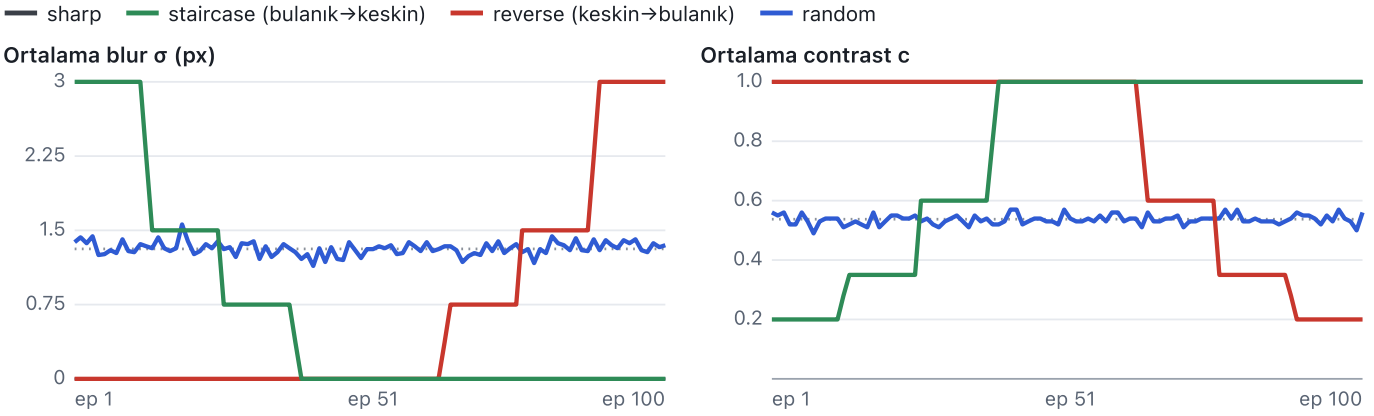
η=0.03 en bozuk kola hızlı gider, son üçte birde uniforma geri döner. Bu "bulanıktan başlama" değil. Kaynak: CV.short.

30 epoch, merdiven uzunluğu: %25, %50, %75



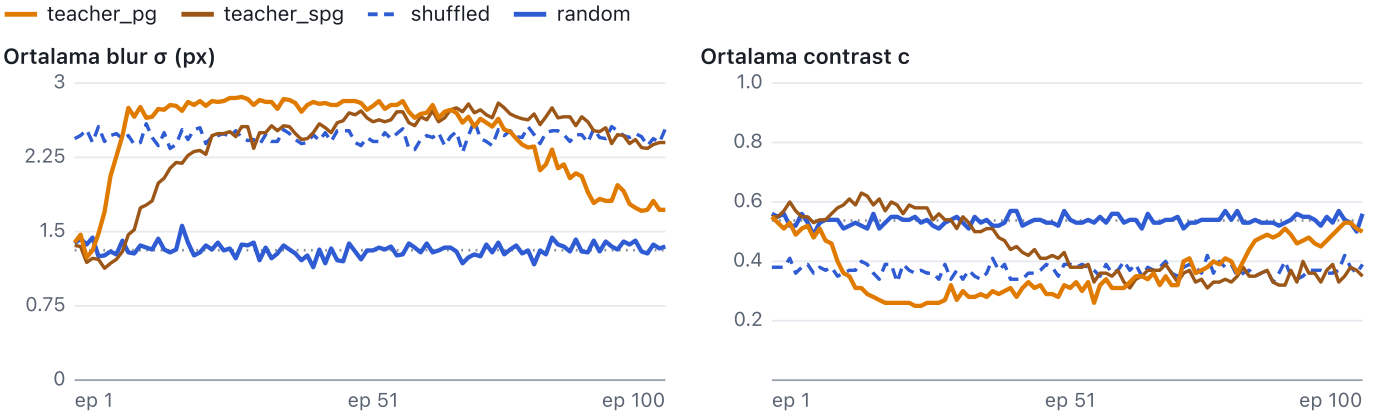
Kaynak: CV.short.

100 epoch, sıralar: aynı desen, daha uzun



Kaynak: CV.full.

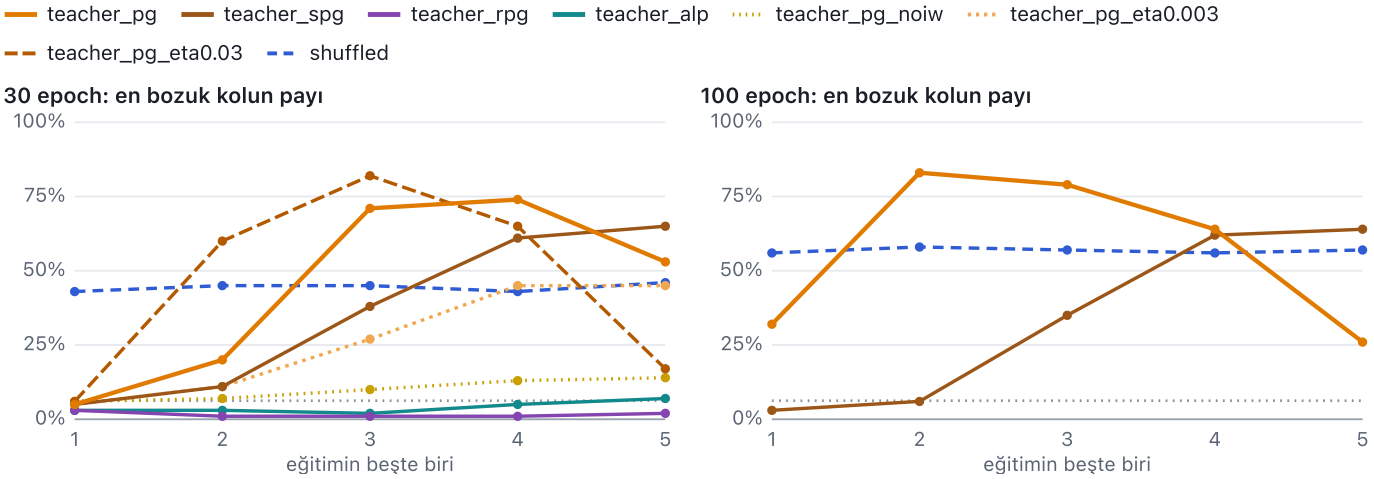
100 epoch, teacher'lar: PG ~epoch 10–70 arası en bozuk bölgede kalır, sonra kısmen geri döner



rpg, alp ve diğer varyantlar 100 epoch'ta koşulmadı. Kaynak: CV.full.

6.3 Teacher nereye gidiyor? En bozuk kolun payı

Ham PG en bozuk kola yığılıyor (%71–83); relative PG ve ALP-GMM uniform düzeyinde kalıyor



En bozuk kol = (σ 3, c 0.2). Eğitim beşe bölündü; her beşte o kolu alan batch payı. Gri noktalı = uniform (1/16 = 0.0625). Kaynak: D[*].worst, `docs/experiments.md` #5, #7–10.

Neden en bozuk kol? Ham PG = loss'taki düşüş. En bozuk kolda loss en yüksektir; bir SGD adımı orada loss'u en çok düşürür. Bu yüzden ham ödül orada en büyük. RPG bu ölçeği loss'a bölerek kaldırır. Sonuç: en bozuk kolun payı %71–74'ten (PG, 30 epoch orta) %1–3'e iner (RPG). Bu açıklamayı RPG deneyi destekliyor. Ama kol başına ödül dağılımına doğrudan bakmadık (`teacher.npz` içinde ödüller kayıtlı; analiz yapılmadı).

6.4 Üç sıra: bulanık→keskin, keskin→bulanık, rastgele

Aynı kol kümesini farklı zamanlarda görmek. Staircase ve reverse aynı kol sayılarına sahip; sadece zaman yönü ters. Random hep karışık. Sharp referans.

Koşul	Clean	C-görülen	C-görülmeyen	Gürültü	C-contrast	Shape bias σ2	High-pass σ1	PGD 1/255
30 EPOCH								
`staircase` bulanık→keskin	90.7 ±0.2	75.8 ±0.7	78.7 ±0.0	68.3 ±0.4	68.8 ±0.4	18.8 ±0.7	65.7 ±1.2	55.0 ±0.5
`reverse` keskin→bulanık	84.4 ±0.2	78.1 ±0.1	71.3 ±0.8	55.0 ±2.4	**74.1** ±0.4	10.5 ±1.0	75.0 ±0.5	26.7 ±1.2
`random` rastgele	89.4 ±0.2	**81.4** ±0.3	**82.2** ±0.1	**76.4** ±0.1	69.3 ±0.8	22.7 ±1.2	66.1 ±2.4	**59.5** ±1.0
`sharp` keskin (referans)	**93.2** ±0.1	69.6 ±0.4	73.3 ±0.1	55.5 ±0.1	73.8 ±0.6	6.2 ±0.4	80.2 ±0.8	34.8 ±0.6
100 EPOCH								
`staircase` bulanık→keskin	93.1 ±0.2	77.0 ±0.8	78.8 ±0.6	64.0 ±1.6	71.5 ±0.2	12.2 ±0.5	75.7 ±0.4	**57.8** ±0.1
`reverse` keskin→bulanık	86.0 ±0.2	80.9 ±0.3	71.9 ±0.7	52.1 ±2.1	74.4 ±0.4	10.9 ±0.3	74.9 ±1.5	18.6 ±2.0
`random` rastgele	92.2 ±0.0	**85.3** ±0.2	**84.4** ±0.1	**76.7** ±0.2	72.9 ±0.7	23.5 ±0.2	65.9 ±1.1	56.6 ±0.5
`sharp` keskin (referans)	**94.8** ±0.0	73.5 ±0.9	75.0 ±0.5	54.3 ±1.3	**76.1** ±0.3	4.7 ±0.2	85.0 ±0.2	44.9 ±0.2

Kalın = sütundaki en iyi (shape bias ve high-pass hariç: onlar "iyi/kötü" değil, bir eğilim). Kaynak: D["short:*"], D["full:*"].

- **Bulanık→keskin (staircase):** clean'i korur (93.1, 100 ep). C'de sharp'tan iyi (+3.5 / +3.8), random'dan kötü (−8.3 / −5.6). PGD'de 100 epoch'ta en yüksek (57.8 ± 0.1; random 56.6 ± 0.5).
- **Keskin→bulanık (reverse):** son epoch'larda bulanık gördüğü için C-görülen yüksek (80.9). Ama clean düşer (86.0), C-görülmeyen en kötü (71.9) ve PGD çöker (18.6, sharp'tan bile 26 puan düşük).
- **Rastgele (random):** C'de açık ara en iyi. Clean'de staircase'ten 0.9 puan düşük.
- Yani yön önemli: reverse açıkça kötü. Ama bulanık→keskin, aynı kolları karışık görmekten daha iyi değil.

6.5 Hangi eksen, hangi rejim?

Koşul	Clean	C-görülen	C-görülmeyen	C-contrast	Gürültü	PGD 1/255
`sharp` BN, hep keskin	**93.2** ±0.1	69.6 ±0.4	73.3 ±0.1	73.8 ±0.6	55.5 ±0.1	34.8 ±0.6
`random` BN, batch başına rastgele kol	89.4 ±0.2	81.4 ±0.3	**82.2** ±0.1	69.3 ±0.8	**76.4** ±0.1	**59.5** ±1.0
`random_blur` BN, sadece blur ekseni	90.8 ±0.3	82.1 ±0.3	81.9 ±0.2	67.2 ±0.6	73.8 ±0.1	56.4 ±0.5
`random_contrast` BN, sadece contrast ekseni	92.7 ±0.2	68.2 ±0.3	73.6 ±0.3	76.1 ±1.0	57.4 ±1.1	31.2 ±1.2
`random_image` BN, görüntü başına rastgele kol	89.6 ±0.0	**86.9** ±0.1	81.2 ±0.2	**88.9** ±0.1	71.7 ±0.7	37.0 ±1.0
`sharp_gn` GroupNorm, hep keskin	90.2 ±0.3	79.6 ±0.4	78.8 ±0.5	87.6 ±0.6	69.4 ±1.4	38.2 ±1.5
`random_gn` GroupNorm, batch başına rastgele	84.7 ±0.2	83.0 ±0.2	79.7 ±0.1	84.8 ±0.2	76.2 ±0.1	49.4 ±0.3
`teacher_pg_gn` GroupNorm, teacher_pg	79.0 ±0.3	78.3 ±0.3	74.6 ±0.3	79.4 ±0.3	72.3 ±0.4	43.2 ±0.6

30 epoch. Kaynak: D["short:*"], `docs/experiments.md` #11–13.

- **Blur ekseni robustness veriyor.** random_blur C 82.1 / 81.9, random ile aynı. random_contrast 68.2 / 73.6, sharp ile aynı.
- **Contrast sadece görüntü başına veya BN'siz öğreniliyor.** C-contrast: batch başına random 69.3, görüntü başına 88.9. BN'li sharp 73.8, GroupNorm'lu sharp 87.6. Batch başına random_contrast sadece 76.1.
- **Bedel.** GroupNorm 30 epoch'ta clean'den ~3 puan kaybettiriyor (90.2 vs 93.2). random_image'ın PGD'si düşük (37.0).
- GroupNorm ile teacher_pg yine hard-first (son beşte en bozuk kol payı 0.50).

Elle merdivenin uzunluğu

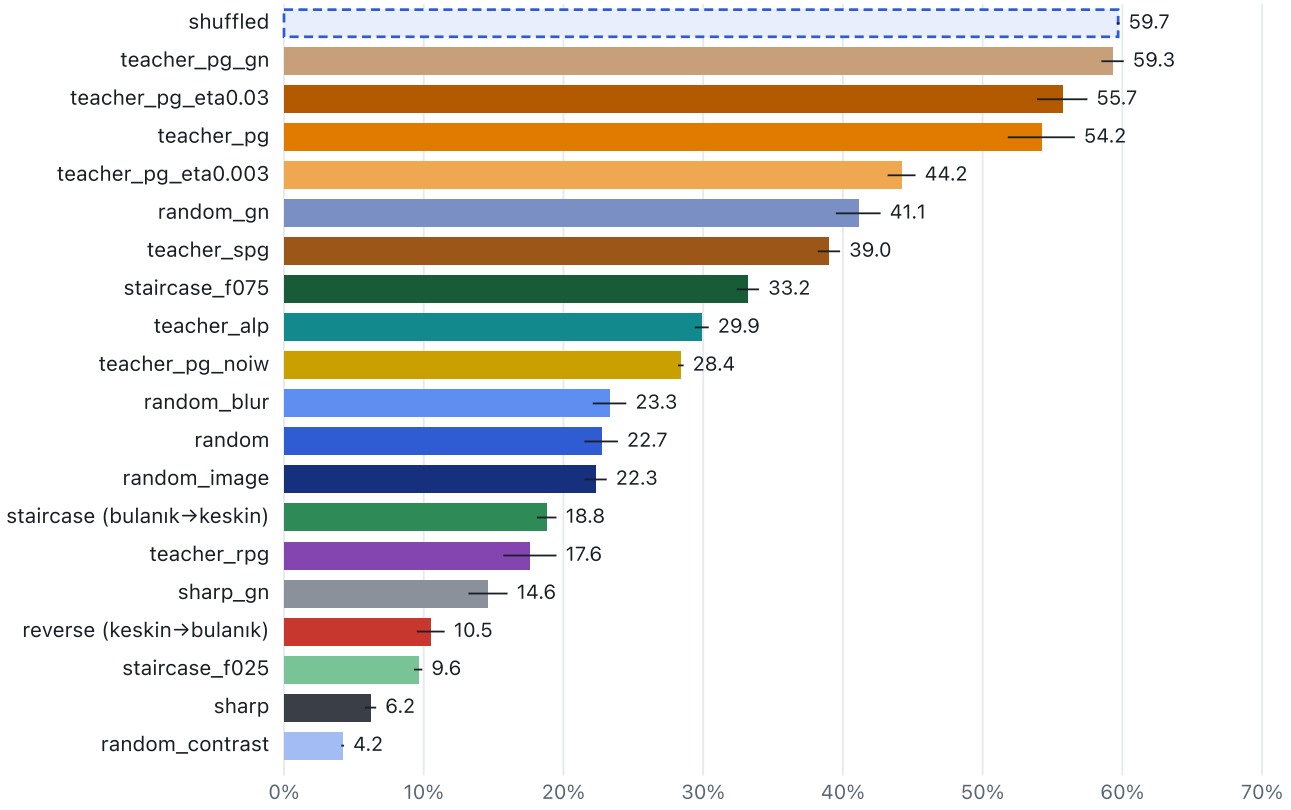
Koşul	Clean	C-görülen	C-görülmeyen	Gürültü	Shape bias σ2	PGD 1/255
`staircase_f025` %25	**92.0** ±0.1	71.0 ±0.9	74.8 ±0.4	58.9 ±1.1	9.6 ±0.3	41.0 ±0.8
`staircase` %50 (varsayılan)	90.7 ±0.2	75.8 ±0.7	78.7 ±0.0	68.3 ±0.4	18.8 ±0.7	55.0 ±0.5
`staircase_f075` %75	88.5 ±0.1	78.9 ±0.1	80.3 ±0.2	75.0 ±0.2	33.2 ±0.8	56.1 ±0.7
`random` referans	89.4 ±0.2	**81.4** ±0.3	**82.2** ±0.1	**76.4** ±0.1	22.7 ±1.2	**59.5** ±1.0

30 epoch. Kaynak: D["short:staircase*"], `docs/experiments.md` #14.

Bulanık faz uzadıkça robustness artar, clean düşer. %75 merdiven bile C'de random'ın altında (78.9 / 80.3 vs 81.4 / 82.2). Bu, "ne kadar blur görüldü" etkisiyle tutarlı.

6.6 Shape bias ve adversarial (PGD)

Shape bias, en bozuk kolda en çok zaman geçiren modellerde en yüksek; sıra değil maruziyet



Hibrit görüntülerin düşük frekans sınıfıyla sınıflandırılma payı (σ=2), 30 epoch. Shuffled (açık dolgu) teacher_pg ile aynı kolları sırasız görür. Kaynak: D["short:*"].bias2, `*/probe.json`.

Koşul	Shape bias σ2	High-pass σ1	PGD 1/255
30 EPOCH			
`sharp`	6.2 ±0.4	80.2 ±0.8	34.8 ±0.6
`staircase`	18.8 ±0.7	65.7 ±1.2	55.0 ±0.5
`reverse`	10.5 ±1.0	75.0 ±0.5	26.7 ±1.2
`random`	22.7 ±1.2	66.1 ±2.4	59.5 ±1.0
`shuffled`	59.7 ±0.1	35.7 ±0.9	51.2 ±0.1
`teacher_pg`	54.2 ±2.4	39.7 ±1.5	49.3 ±0.9
`teacher_spg`	39.0 ±0.8	52.9 ±1.0	54.0 ±0.1
`teacher_rpg`	17.6 ±1.9	66.4 ±1.9	58.0 ±0.9
`teacher_pg_noiw`	28.4 ±0.2	61.6 ±1.5	**59.7** ±0.8
`random_blur`	23.3 ±1.2	66.8 ±0.9	56.4 ±0.5
`random_image`	22.3 ±0.8	81.8 ±0.1	37.0 ±1.0
100 EPOCH			
`sharp`	4.7 ±0.2	85.0 ±0.2	44.9 ±0.2
`staircase`	12.2 ±0.5	75.7 ±0.4	**57.8** ±0.1
`reverse`	10.9 ±0.3	74.9 ±1.5	18.6 ±2.0
`random`	23.5 ±0.2	65.9 ±1.1	56.6 ±0.5
`shuffled`	68.7 ±0.8	27.6 ±4.8	49.3 ±1.2
`teacher_pg`	66.6 ±0.4	26.9 ±0.1	48.5 ±0.6
`teacher_spg`	61.2 ±0.5	34.4 ±1.2	46.9 ±1.0

PGD-10, ε=1/255, 2000 test görüntüsü. Kaynak: D[*].pgd1, bias2, high1; `docs/experiments.md` #15–16.

- Shape bias, en bozuk kolda geçen süreyle artıyor: sharp 6.2 → random 22.7 → teacher_pg 54.2 → shuffled 59.7 (30 ep).
- Bedel: yüksek frekans doğruluğu düşüyor. High-pass σ1: sharp 80.2, teacher_pg 39.7, shuffled 35.7.
- PGD'ye blur yardım ediyor: sharp 34.8 → random 59.5 (30 ep). teacher_pg_noiw 59.7 ile aynı düzeyde.
- Reverse en kötü (26.7 / 18.6). random_image C'de iyi ama PGD'de düşük (37.0).

---

7. Yorum: ne kadar eminiz?

SAĞLAM

Hiçbir teacher bulanıktan başlamadı. 7 teacher varyantı (pg, spg, rpg, alp, η×2, noiw) + GroupNorm'lu pg, hepsi 3 seed. Hepsi uniform civarında başlıyor. Ham PG/SPG zamanla en bozuk kola kayıyor; rpg/alp uniforma yakın kalıyor. H1 bu kurulumda reddedildi.

SAĞLAM

100 epoch'ta CIFAR-10-C'de hiçbir sıra random'ı geçmedi. Random 85.3 / 84.4; en yakın teacher_spg 82.5 / 80.7. Fark std'nin (≤0.9) çok üstünde.

SAĞLAM

Robustness'ı blur veriyor, contrast değil. random_blur ≈ random; random_contrast ≈ sharp (30 ep).

SAĞLAM

Contrast sadece görüntü başına veya GroupNorm ile öğreniliyor. Bu, contrast bozulmasında ölçüldü: 88.9 ve 87.6 vs batch başına 69.3. Ama BN mekanizması bir açıklama; doğrudan aktivasyon analizi yapmadık.

İNCE AYRIM

teacher_pg ve shuffled "çok yakın", aynı değil. Robustness farkı küçük ve teacher lehine: clean +0.6 / +0.8, C-görülen +0.4 / +0.6, C-görülmeyen +0.3 / +0.2 (30 / 100 ep). Std 0.1–0.3, yani fark gürültüden biraz büyük; ama 3 seed ile zayıf kanıt. Shape bias ve PGD'de ise shuffled önde: shape bias 59.7 vs 54.2 (30 ep), 68.7 vs 66.6 (100 ep); PGD 51.2 vs 49.3 (30 ep), 49.3 vs 48.5 (100 ep). Sonuç: teacher'ın sırası robustness'a ölçülebilir bir katkı yapmıyor; ama "sıra tamamen önemsiz" de diyemeyiz.

İNCE AYRIM

Sıranın yönü önemli. Reverse açıkça en kötü: C-görülmeyen 71.9, PGD 18.6 (100 ep). Yani "sıra önemsiz" değil; "bulanık→keskin, karışık görmekten iyi değil".

İNCE AYRIM

"Random en iyi" 7 ana koşul arasında ve 100 epoch'ta geçerli. 30 epoch'ta bazı yeni varyantlar eşit veya kısmen daha iyi: random_image C-görülen'de 86.9 (random 81.4) ama C-görülmeyen'de 81.2 (random 82.2); teacher_rpg 90.0 / 81.1 / 82.4 ≈ random; random_blur clean ve C-görülen'de +1.4 / +0.7. Bunlar 100 epoch'ta koşulmadı. Ayrıca PGD'de 100 ep staircase random'dan 1.2 puan yüksek.

AÇIKLAMA, KANIT DEĞİL

"Teacher en bozuk kola gidiyor çünkü loss düşüşü orada en büyük." RPG deneyi bunu destekliyor (ölçek kalkınca hard-first kayboluyor). Ama kol başına ödül dağılımını doğrudan analiz etmedik.

Sınırlamalar

- Tek veri seti (CIFAR-10, 32 px) ve tek model (ResNet-18). 32 px görüntüde σ=3 blur çok ağır.
- 3 seed. Std'ler küçük ama 1 puandan küçük farklar için kanıt zayıf.
- Shape bias bir frekans proxy'si (düşük vs yüksek frekans hibriti). Geirhos'un stil transferi testi değil.
- FGSM gradient masking'e benziyor: sharp 100 ep'te FGSM 2/255 (53.6) PGD 1/255'ten (44.9) yüksek. Bu yüzden sadece PGD kullanılıyor.
- BN recalibration bir tercih. Başka bir seçenek (örn. eğitimde de karışık batch) farklı clean sayıları verebilir.
- ALP-GMM sürekli uzayda örnekliyor ama eğitim 16 kola yuvarlıyor. Sürekli sürüm denenmedi.
- random_image'ın kol log'u sadece ilk görüntünün kolunu saklıyor (histogram yansız ama tam değil).
- Arslan ve ark.'nın gürültü testleri (Gaussian, salt-and-pepper girdi) ayrıca koşulmadı. CIFAR-10-C'nin gürültü bozulmaları sadece yakın bir karşılık.
- Yeni 13 varyant sadece 30 epoch'ta koşuldu.

---

8. Açık sorular ve sonraki adımlar

Sonraki deneyler

1. **100 epoch varyantlar:** random_image, random_blur, teacher_rpg, teacher_alp (~40 dk A100). "Random en iyi" sonucunun bunlara karşı tutup tutmadığını gösterir.
2. **Görüntü başına teacher:** teacher tek kol yerine batch için bir dağılım seçer. Görüntü başına karışımın contrast avantajını teacher ile birleştirir.
3. **Transfer progress ödülü:** ödül = temiz (keskin) validation batch'indeki loss düşüşü. Teacher'ı "en çok öğrenilen kola" değil "keskin görmeye en çok yardım eden kola" yönlendirir. Robustness yine ödülde değil.
4. Kol başına ödül analizi (`teacher.npz`): hard-first açıklamasını doğrudan test eder.

Danışmana sorular

- H1'in reddi (ham PG ile hard-first) yeterli bir sonuç mu, yoksa ödülü değiştirerek (transfer progress) aramaya devam edelim mi?
- Frekans tabanlı shape bias proxy'si yeterli mi, yoksa stil transferli bir CIFAR shape bias seti mi kuralım?
- Arslan ve ark.'nın gürültü testlerini ve iç gürültü fikrini ekleyelim mi?
- Daha büyük veri (örn. Tiny-ImageNet) bütçe açısından mantıklı mı?

9. Ekler

Ek A — 30 epoch, 20 koşul

Koşul	Clean	C-görülen	C-görülmeyen	Gürültü	C-contrast	Shape bias σ2	High-pass σ1	PGD 1/255
ANA KOŞULLAR								
`sharp`	**93.2** ±0.1	69.6 ±0.4	73.3 ±0.1	55.5 ±0.1	73.8 ±0.6	6.2 ±0.4	80.2 ±0.8	34.8 ±0.6
`staircase`	90.7 ±0.2	75.8 ±0.7	78.7 ±0.0	68.3 ±0.4	68.8 ±0.4	18.8 ±0.7	65.7 ±1.2	55.0 ±0.5
`reverse`	84.4 ±0.2	78.1 ±0.1	71.3 ±0.8	55.0 ±2.4	74.1 ±0.4	10.5 ±1.0	75.0 ±0.5	26.7 ±1.2
`random`	89.4 ±0.2	81.4 ±0.3	82.2 ±0.1	**76.4** ±0.1	69.3 ±0.8	22.7 ±1.2	66.1 ±2.4	59.5 ±1.0
`shuffled`	84.2 ±0.3	79.7 ±0.2	78.5 ±0.1	75.4 ±0.2	63.7 ±0.5	59.7 ±0.1	35.7 ±0.9	51.2 ±0.1
`teacher_pg`	84.8 ±0.3	80.1 ±0.2	78.8 ±0.2	74.8 ±0.3	64.1 ±0.3	54.2 ±2.4	39.7 ±1.5	49.3 ±0.9
`teacher_spg`	87.0 ±0.1	81.0 ±0.2	80.3 ±0.1	75.4 ±0.3	66.3 ±0.9	39.0 ±0.8	52.9 ±1.0	54.0 ±0.1
A — TEACHER VARYANTLARI								
`teacher_rpg`	90.0 ±0.2	81.1 ±0.4	**82.4** ±0.1	76.3 ±0.6	70.5 ±0.6	17.6 ±1.9	66.4 ±1.9	58.0 ±0.9
`teacher_pg_eta0.003`	86.6 ±0.0	81.1 ±0.1	80.2 ±0.2	75.5 ±0.5	66.1 ±0.5	44.2 ±1.0	49.2 ±1.5	53.3 ±1.3
`teacher_pg_eta0.03`	84.6 ±0.3	79.9 ±0.2	78.8 ±0.2	75.5 ±0.3	64.1 ±0.7	55.7 ±1.8	38.4 ±3.6	51.3 ±0.4
`teacher_pg_noiw`	88.8 ±0.1	81.6 ±0.2	81.7 ±0.0	75.9 ±0.1	68.8 ±0.4	28.4 ±0.2	61.6 ±1.5	**59.7** ±0.8
`teacher_alp`	89.0 ±0.5	82.1 ±0.1	82.0 ±0.4	**76.4** ±0.8	67.7 ±0.8	29.9 ±0.5	61.3 ±1.5	56.6 ±1.1
B — REJİM VE EKSEN								
`random_image`	89.6 ±0.0	**86.9** ±0.1	81.2 ±0.2	71.7 ±0.7	**88.9** ±0.1	22.3 ±0.8	81.8 ±0.1	37.0 ±1.0
`random_blur`	90.8 ±0.3	82.1 ±0.3	81.9 ±0.2	73.8 ±0.1	67.2 ±0.6	23.3 ±1.2	66.8 ±0.9	56.4 ±0.5
`random_contrast`	92.7 ±0.2	68.2 ±0.3	73.6 ±0.3	57.4 ±1.1	76.1 ±1.0	4.2 ±0.1	81.6 ±1.5	31.2 ±1.2
`staircase_f025`	92.0 ±0.1	71.0 ±0.9	74.8 ±0.4	58.9 ±1.1	71.9 ±0.1	9.6 ±0.3	76.9 ±0.6	41.0 ±0.8
`staircase_f075`	88.5 ±0.1	78.9 ±0.1	80.3 ±0.2	75.0 ±0.2	64.5 ±0.8	33.2 ±0.8	50.8 ±3.8	56.1 ±0.7
B — GROUPNORM								
`sharp_gn`	90.2 ±0.3	79.6 ±0.4	78.8 ±0.5	69.4 ±1.4	87.6 ±0.6	14.6 ±1.4	72.9 ±0.9	38.2 ±1.5
`random_gn`	84.7 ±0.2	83.0 ±0.2	79.7 ±0.1	76.2 ±0.1	84.8 ±0.2	41.1 ±1.6	70.7 ±1.2	49.4 ±0.3
`teacher_pg_gn`	79.0 ±0.3	78.3 ±0.3	74.6 ±0.3	72.3 ±0.4	79.4 ±0.3	59.3 ±0.8	60.7 ±1.2	43.2 ±0.6

Ek B — 100 epoch, 7 koşul

Koşul	Clean	C-görülen	C-görülmeyen	Gürültü	C-contrast	Shape bias σ2	High-pass σ1	PGD 1/255
`sharp`	**94.8** ±0.0	73.5 ±0.9	75.0 ±0.5	54.3 ±1.3	**76.1** ±0.3	4.7 ±0.2	85.0 ±0.2	44.9 ±0.2
`staircase`	93.1 ±0.2	77.0 ±0.8	78.8 ±0.6	64.0 ±1.6	71.5 ±0.2	12.2 ±0.5	75.7 ±0.4	**57.8** ±0.1
`reverse`	86.0 ±0.2	80.9 ±0.3	71.9 ±0.7	52.1 ±2.1	74.4 ±0.4	10.9 ±0.3	74.9 ±1.5	18.6 ±2.0
`random`	92.2 ±0.0	**85.3** ±0.2	**84.4** ±0.1	**76.7** ±0.2	72.9 ±0.7	23.5 ±0.2	65.9 ±1.1	56.6 ±0.5
`shuffled`	85.4 ±0.1	80.9 ±0.1	79.5 ±0.1	**76.7** ±0.4	63.1 ±0.9	68.7 ±0.8	27.6 ±4.8	49.3 ±1.2
`teacher_pg`	86.2 ±0.1	81.5 ±0.2	79.7 ±0.1	76.1 ±0.6	63.6 ±0.4	66.6 ±0.4	26.9 ±0.1	48.5 ±0.6
`teacher_spg`	87.1 ±0.2	82.5 ±0.3	80.7 ±0.1	**76.7** ±0.3	65.8 ±0.8	61.2 ±0.5	34.4 ±1.2	46.9 ±1.0

Ortalama ± std, 3 seed, %. Gürültü = 4 gürültü bozulmasının ortalaması. Kaynak: Drive `results/{short,full}_summary.json` → `src/digest.py`.

Ek C — Deney günlüğü özeti

#	Tarih	Deneme	Neden	Sonuç
1	11-03	Sharp, 30 ep, seed 0	Pipeline doğru mu?	Clean 93.2 (hedef ~93)
2	11-03	eager vs torch.compile	Hangi mod?	2.0 vs 1.7 s/epoch, derleme 30 s → eager
3	11-03	Pilot: 7 koşul, seed 0	Hepsi koşuyor mu?	Karışık koşullar clean %13–60 → BN şüphesi
4	11-03	BN recalibration	BN hipotezi	Doğrulandı: random 60→89, teacher_spg 16→87; sharp aynı
5	11-04	F5: 7 × 3 × 30 ep	Ana karşılaştırma	Random en iyi; teacher en bozuk kola gidiyor
6	11-08	F6: 7 × 3 × 100 ep	Tam bütçede tutuyor mu?	Aynı sıralama; random 92.2 / 85.3 / 84.4
7	11-08	A1 teacher_rpg	Hard-first PG ölçeğinden mi?	Evet: en bozuk kol payı %1–3 (PG %71–74)
8	11-08	A2 η 0.003 / 0.03	η hassasiyeti	Sadece hız değişiyor; ikisi de hard-first
9	11-08	A4 importance weighting yok	Güncelleme ayrıntısı	Yavaş kayma (son beşte %14)
10	11-08	A3 ALP-GMM	Farklı teacher	Uniforma yakın; ≈ random
11	11-08	B1 görüntü başına rastgele	Contrast gerçek olur mu?	Evet: C-contrast 88.9 (batch başına 69.3); PGD düşük 37.0
12	11-08	B2 GroupNorm	BN bağımlılığı	GN sharp C-contrast 87.6; clean –3; teacher yine hard-first
13	11-08	B3 random_blur / random_contrast	Hangi eksen?	Blur: 82.1 / 81.9; contrast ≈ sharp
14	11-08	B4 staircase %25 / %75	Merdiven uzunluğu	Uzun bulanık faz → daha robust, daha az clean
15	11-08	C1 shape bias, low/high-pass	Shape vs texture	Maruziyeti izliyor, sırayı değil
16	11-08	C2 FGSM, PGD-10	Adversarial	Blur PGD'ye yardım ediyor; FGSM güvenilmez
17	11-08	OOM (12 paralel)	—	3 koşu 6 paralel ile checkpoint'ten yeniden

Kaynak: `docs/experiments.md`.

Ek D — Dosyalar nerede?

Ne	Nerede
Kod	`src/` : `degrade.py` (blur, contrast, kollar), `schedule.py` (koşullar), `teacher.py` (Exp3.S, PG/SPG/RPG), `teacher_alp.py`, `train.py`, `eval.py` (CIFAR-10-C, BN recal), `probe.py` (shape bias, filtreler, FGSM/PGD), `collect.py`, `digest.py`, `blur_curve.py`
Config'ler	`configs/<short|full>/<koşul>_s<seed>.json`, `python -m src.make_configs` ile üretilir
Colab script'leri	`colab/README.md`, `run_budget.sh` (7 ana koşul), `run_conds.sh` (seçili koşullar, paralel), `finish_ext.sh` (OOM sonrası)
Testler	`tests/` (pytest)
Ham sonuçlar (Drive)	`MyDrive/auto-curriculum/results/<short|full>/<koşul>/<seed>/{eval.json, probe.json, arms.npy}` + `last.pt`, `metrics.jsonl`, teacher koşularında `teacher.npz`
Özetler (Drive)	`results/{short,full}_summary.json`, loglar `logs/`
Dokümanlar	`docs/progress.md`, `docs/experiments.md`, `docs/plans/`, `docs/okuma/`, `docs/project_proposal.pdf`

Ek E — Tekrar üretme

Colab'da (A100), her blok bir hücre. Ayrıntı: `colab/README.md`.

```
from google.colab import drive; drive.mount('/content/drive')

%%bash
cd /content && git clone https://github.com/omarreis01/autofocus-curriculum.git
cd autofocus-curriculum && pip install -q -r requirements.txt
python -m src.data --data-dir /content/data        # ~1.5 dk, HF mirror
python -m src.smoke --data-dir /content/data

# 7 ana koşul, kısa bütçe, 3 seed (shuffled teacher_pg'den sonra koşar)
bash colab/run_budget.sh short 0 1 2
# 100 epoch
bash colab/run_budget.sh full 0 1 2
# genişletilmiş koşullar: 6 paralel, train + eval + probe
bash colab/run_conds.sh short 6 "0 1 2" teacher_rpg teacher_alp random_image random_blur ...
# özet
python -m src.collect --results $D/results/short --epochs 30 > $D/results/short_summary.json
```

Yerelde (CPU) testler:

```
uv venv --python 3.13 .venv
uv pip install --python .venv/bin/python torch torchvision --index-url https://download.pytorch.org/whl/cpu
uv pip install --python .venv/bin/python -r requirements.txt
.venv/bin/python -m pytest -q tests
.venv/bin/python -m src.smoke --fake-data
```

Bu rapordaki tüm sayılar `docs/reports/pilot-short-s0.html` içindeki D ve CV verisinden (Drive özetlerinden üretildi) ve `docs/experiments.md` 'den alındı. Grafikler bu dosyanın içinde, sayfa açılırken çizilir.